

Felix Ekbrant
Harald Janson
Ludvig Bergström
Eddie Xia

Skadefrekvensanalys - Entreprenadförsäkring

ME1316 - Grupp 40

1. Inledning.....	3
2. Ämnesbeskrivning	3
3. Metod och data	4
3.1 Data	4
3.2 Valideringslogik	4
3.3 Deskriptiv analys	4
3.4 Poisson-GLM.....	6
3.5 XGBoost.....	7
3.6 Modelljämförelse.....	7
3.7 Osäkerhetsanalys	7
4. Resultat	8
4.1 Poisson-GLM.....	8
4.2 XGBoost-resultat	9
4.3 Modelljämförelse.....	9
4.4 Osäkerhet i prediktioner	9
5. Analys	9
5.1 Samlad tolkning av riskmönster	9
5.2 Modellval	10
5.3 Antaganden och begränsningar.....	10
5.4 Praktisk användning och osäkerhet	11
6. Slutsats	12
7. Referenslista	13
8. Appendix.....	14
8.1 Github	14

1. Inledning

I skadeförsäkring ska premien spegla den risk kunden förväntas bidra med. Risken kan delas upp i två delar: hur ofta skador inträffar och hur stora kostnaderna blir när en skada väl sker. Detta projekt fokuserar på den första delen, skadefrekvensen. Resultaten kan därför inte ensamma ge en fullständig premie i kronor, men det kan visa vilka faktorer som påverkar förväntat skadeantal, vilket är direkt tillämpligt i en senare prissättningsmodell.

Syftet är att undersöka om skadeantal kan förutsägas med hjälp av kund-, verksamhets- och försäkringsdata. Analysen ska därmed både ge en prognos för framtida skadeantal och fungera som beslutsunderlag för prissättning och segmentering. Projektets huvudfråga är: *Hur väl kan skadeantal i entreprenadförsäkring förutsägas med hjälp av kund-, verksamhets- och försäkringsdata?*

För att besvara huvudfrågan undersöks följande delfrågor:

- *Vilka portföljsegment har högst respektive lägst skadefrekvens?*
- *Vilka variabler framstår som mest relevanta ratingfaktorer?*

Projektet jämför en Poisson-GLM, som är transparent och etablerad för skadeantal, med XGBoost, en mer flexibel maskininlärningsmodell. Syftet är att undersöka om den ökade flexibiliteten ger praktiskt mervärde som motiverar lägre tolkningsbarhet, det vill säga om ML-modellen kan tillföra ökad precision utan att modellen blir svår att förklara, följa upp eller omsätta i premiejusteringar. Vidare diskuteras vilka osäkerheter och begränsningar som bör beaktas innan modellen kan användas som underlag i en prissättningskontext.

2. Ämnesbeskrivning

Entreprenadförsäkring omfattar företag med varierande verksamhet, storlek och geografisk placering. En mindre hantverkare och ett större byggföretag kan tillhöra samma breda försäkringsområde, men ändå ha olika arbetsmoment, projektvolym och skadebild. För prissättning räcker det därför inte att betrakta portföljen som en homogen grupp.

I försäkring används ratingfaktorer för att skilja mellan kunder med olika förväntad risk. I företagsförsäkring är verksamhetstyp, geografiskt område och ekonomisk storlek typiska exempel. De säger något om vad kunden gör, var arbetet sker och hur omfattande den exponerade verksamheten är. I detta projekt undersöks vilka av dessa faktorer som tydligast samvarierar med skadefrekvensen.

Analyslogiken följer den tredelade strukturen beskriven i Broström (2022). Först används deskriptiv analys för att beskriva portföljen och identifiera skillnader mellan segment. Därefter används prediktiv analys för att modellera och förutsäga skadeantal på osedda

data. Slutligen används resultaten preskriptivt, genom att översätta modellresultaten till rekommendationer om prissättning, segmentering och fortsatt datainsamling.

3. Metod och data

3.1 Data

Projektet bygger på artificiell försäkringsdata uppdelad i en träningsfil för 2021–2024 och en testfil för 2025. Träningsfilen omfattar 1 033 386 rader med 19 730 skador, testfilen 291 649 rader med 5 520 skador. Varje rad representerar ett försäkringskontrakt med information om Verksamhet, Geografiskt Område, exponeringstiden Duration (andel av ett år), AntalSkador samt Försäkringsbelopp, Omsättning och Självrisk.


Innan modelleringen kontrollerades datan. Inga saknade värden förekom, datatyperna var korrekta, och kategorinivåerna för Verksamhet och Geografiskt Område var identiska i tränings- och testfilen. Alla värden på Duration låg inom (0, 1]. De ekonomiska variablerna är högerskeva, men extremvärden bedömdes representera stora och verkliga kunder snarare än fel. AntalSkador är koncentrerad kring noll med cirka 98 % nollskador. Inga rensningar, imputeringar eller trunkeringar genomfördes.

3.2 Valideringslogik

För att efterlikna en verklig prognossituation delades träningsfilen tidsmässigt. Kandidatmodellerna tränades på 2021–2023 och utvärderades på valideringsåret 2024. Den valda slutmodellen tränades om på hela träningsfilen 2021–2024. Testfilen för 2025 reserverades för slutlig utvärdering. Att basera modellvalet på testfilen hade introducerat look-ahead bias, det vill säga att information från framtiden indirekt påverkar modellvalet och gör utvärderingen för optimistisk.


3.3 Deskriptiv analys

Den deskriptiva analysen fungerade som ett filter inför modellbygget. Variabler med tydliga skillnader i skadefrekvens togs vidare som kandidater, medan övriga variabler krävde noggrannare analys.




Figur 1 - Visar hur skador per exponerat år varierar mellan verksamheter (se kolumner) och geografiska områden (se rader).

Skadefrekvensen varierar tydligt mellan verksamhet och geografiskt område, vilket motiverar att variablerna bör testas i modellen.



Figur 2 – Visar hur decilerna av omsättning och försäkringsbelopp korrelerar med skadefrekvens per exponerat år.

Skadefrekvensen ökar monotont med ungefär en faktor 5,6 från lägsta till decilen för omsättning. Försäkringsbelopp visar liknande men svagare samband med en faktor kring 3,2.



Figur 3 - Visar samvariation mellan omsättning, försäkringsbelopp och självrisk. Alla variabler i matrisen är log-transformerade

Försäkringsbelopp exkluderades för att undvika multikolinariet då den efter decilanalyser och korrelationsmatrisen bedömdes bära på liknande information som omsättning. Sambandet har testats internt och vidare motivering för exkludering finns i 5.1. Omsättning har starkare samband med skadefrekvens och väljs som ekonomisk storleksvariabel.

3.4 Poisson-GLM

Skadeantal är count-data (icke-negativa heltal) och modellerades därför med en Poisson-GLM. Vanlig linjär regression är inte lämplig eftersom den kan ge negativa prediktioner. Poissonfördelningen kombineras med en log-länk så att logaritmen av det förväntade skadeantalet är linjär i riskfaktorerna. Det säkerställer positiva prediktioner och gör att effekterna kan tolkas som procentuella skillnader i skadefrekvens. Duration behandlas som exponering, eftersom kontraktets längd antas ha ett proportionellt samband med antalet skador, och inkluderas som en offset $\log(\text{Duration})$ vars koefficient är låst till ett. Modellstrukturen blir: $\log(E[\text{AntalSkador}]) = \log(\text{Duration}) + \text{modellens riskfaktorer}$

Fyra modeller specificerades sekventiellt: M0 (intercept only), M1 (M0 + Verksamhet + GeografisktOmråde), M2 (M1 + $\log(\text{Omsättning})$) och M3 (M2 + Självrisk). År exkluderades då sambandet med skadefrekvens var svagt och en kategorisk årseffekt kan inte extrapoleras till 2025 och var därför inte ett möjligt val för slutmodellen. Modellerna jämfördes med AIC, som väger passform mot komplexitet, och valideringsdeviance: ett Poissonanpassat felmått beräknat på 2024 där lägre värden indikerar bättre passform. Beslutsregeln var att en slutgiltig GLM-modell valdes om både AIC och valideringsdeviance förbättrades tydligt jämfört med tidigare modeller. För slutmodellen kontrollerades Poissonantagandet om $\text{var}(Y) = E(Y)$ med Pearson $\chi^2/\text{frihetsgrader}$, där en kvot nära ett

indikerar att antagandet håller; ett värde klart över ett hade motiverat ett mer flexibelt alternativ som negativ binomial.

GLM-koefficienter skattas på log-skala. Genom att exponentiera en koefficient erhålls en rate ratio, det vill säga en multiplikator på hur skadefrekvensen ändrats relativt en referensnivå. Som referens kategorier används Byggföretag (Verksamhet) och Landsbyggd (Geografiskt Område). För log(Omsättning) redovisas effekten per fördubbling av omsättning, vilket är en mer begriplig tolkningsenhet än per log-enhet.

3.5 XGBoost

XGBoost (Chen & Guestrin, 2016) användes som en jämförelsemodell till Poisson-GLM för att undersöka om en mer flexibel modell kunde förbättra prediktionen. XGBoost implementerar gradientförstärkning (gradient boosting) genom att iterativt kombinera grunda beslutsträd, där varje nytt träd korrigerar felen från de tidigare träden. För en rättvis jämförelse användes samma variabler som i slutgiltiga modellen GLM-modellen. Eftersom utfallet är skadeantal användes en Poisson-anpassad objektivfunktion, och Duration hanterades som exponering genom $\log(\text{Duration})$.

Sex konfigurationer testades med varierande traddjup och inlärningstakt. Antalet träd valdes med early stopping, vilket innebär att träningen avbröts när modellen inte längre förbättrades på valideringsåret 2024. Således användes samma valideringslogik för XGboost som Poisson GLM.

3.6 Modelljämförelse

När modellval och XGBoost-inställningar var bestämda användes testportföljen 2025 för slutlig utvärdering. Testportföljen 2025 användes för utvärdering mellan slutgiltig GLM-modell och XGBoost. Huvudmålet var Poisson deviance, eftersom det är anpassat för skadeantal. Som komplettering användes Root Mean Square Error (RMSE), Mean Absolute Error (MAE), totalt predikterat skadeantal och portföljfel i procent. XGBoost skulle bara väljas framför GLM om förbättringen var tydlig och stabil. En liten förbättring räcker inte, eftersom GLM är enklare att tolka och kan användas mer direkt i prissättning.

3.7 Osäkerhetsanalys

Osäkerhetsanalysen gjordes för att bedöma hur säkra Poisson-GLM:s prediktioner är, både för enskilda försäkringsrader och för hela 2025-portföljen. För varje prediktion beräknades ett 95-procentigt konfidensintervall. Vanliga kundprofiler i träningsdatan får normalt smalare intervall, medan ovanliga profiler får bredare intervall. För att kunna jämföra

osäkerhet mellan kunder med olika risknivåer beräknades även relativ osäkerhet, definierad som konfidensintervallets bredd dividerad med prediktionen.

4. Resultat

4.1 Poisson-GLM

Tabell 1: Resultat från träning av modellerna som underlag till val av model. AIC är in-sample mått från 2021-2023 och valideringsdeviance är out-of-sample mått från 2024.

Modell	Beskrivning	AIC	Valideringsdeviance
M0	Medelvärde justerad för duration	141 086	41 500
M1	Verksamhet + Geografi	139 723	41 200
M2	M1 + log(Omsättning)	136 971	41 002
M3	M2 + självrisk	136 257	40 690

M3 ger marginellt bättre passform på både AIC och valideringsdeviance. Trots detta valdes M2 som slutmodell eftersom Självrisk korrelerar med Omsättning ($r = 0,45$, se Figur 3), delvis speglar försäkringstagarens riskaptit snarare än exponering, och försvårar tolkningen av rate ratios. Förbättringen bedöms inte uppväga den ökade komplexiteten i en prissättningskontext. Vidare motivering återfinns i avsnitt 5.1.

Tabell 2: Resultat av koefficienter och rate ratios efter träning på data 2021-2024 med 95-procentigt konfidensintervall.

Verksamhet	β	Rate ratio	Konfidensintervall
VVS	+0,359	1,432	1,372–1,494
Takarbeten	+0,127	1,135	1,067–1,207
Byggföretag (ref.)	-	1,000	-
Övriga specialistföretag	-0,030	0,970	0,932–1,010
Grävning & Schaktning	-0,157	0,855	0,808–0,905
Elektriker	-0,360	0,698	0,659–0,738
Målare	-0,452	0,637	0,601–0,675
Geografiskt område	β	Rate ratio	Konfidensintervall
Storstad	+0,379	1,461	1,387–1,539
Mellanstorstad	+0,185	1,203	1,140–1,271
Landsbygd (ref.)	-	1,000	-
Småstad	-0,279	0,757	0,711–0,805
Variabel	β	Rate ratio per fördubbling	Konfidensintervall
log(Omsättning)	+0,442	1,358	1,345–1,371

Skattningen av log(omsättning) är omvandlad så att rate-ratio och konfidensintervallet tolkas som effekt per fördubbling av omsättning istället för per log-enhet.

4.2 XGBoost-resultat

Sex konfigurationer testades med olika trädjup och inlärningstakt. De enklare modellerna med trädjup 3 presterade bäst, medan djupare träd gav högre deviance. Det tyder på att mer komplexa samband inte tillförde särskilt mycket i detta datamaterial. Den bästa konfigurationen var $\text{max_depth} = 3$, $\text{learning_rate} = 0,10$ och 232 träd. Feature importance för XGBoost identifierade samma tre drivare som GLM: $\log(\text{omsättning})$ (gain = 20,04) är den klart viktigaste variabeln, följt av geografiskt område (gain = 8,26) och verksamhet (gain = 6,46). Att en flexibel ML-modell landar i samma rangordning stärker förtroendet för GLM:s variabelval och bekräftar att portföljens riskstruktur kan beskrivas med dessa tre faktorer.

4.3 Modelljämförelse

Tabell 3: Modelljämförelse, slutgiltigt resultat 2025

Mått	GLM M2	XGBoost	Skillnad
Totalt predikerat	5 580,6	5 587,3	+6,7
Observerat	5 520	5 520	0
Portföljfel	+1,10%	+1,22%	+0,12 %-enheter
Poisson deviance	41 889,2	41 855,7	-33,4 (-0,08%)
RMSE	0,1374	0,1374	0
MAE	0,0371	0,0371	0

Båda modellerna presterar i stort sett identiskt på osedd data. XGBoost är marginellt bättre på poisson deviance, medan GLM har lite lägre portföljfel.

4.4 Osäkerhet i prediktioner

Osäkerheten i GLM M2:s prediktioner beräknades med 95-procentiga konfidensintervall. För hela 2025-portföljen predikterade modellen 5 581 skador med ett konfidensintervall på [5 503, 5 658], vilket motsvarar en osäkerhet på 2,8%. Det observerade utfallet var 5 520 skador, vilket ligger inom intervallet. Det innebär att den totala prediktionen är rimlig på portföljnivå. På radnivå varierade relativ osäkerhet (5,2%-18,7%) mellan olika kundprofiler. Prediktioner för vanliga profiler i träningsdatan hade smalare intervall, medan ovanliga kombinationer av verksamhet, geografi och omsättning hade bredare intervall.

5. Analys

5.1 Samlad tolkning av riskmönster

Resultaten visar att skadefrekvensen inte är jämnt fördelad i entreprenadportföljen. Skillnaderna mellan verksamheter, geografiska områden och omsättningsnivåer är tillräckligt tydliga för att motivera differentierad prissättning. VVS, storstad och hög

omsättning framstår som de viktigaste riskhöjande faktorerna. Tolkningen är rimlig i försäkringskontext: större företag har fler projekt och fler exponeringspunkter, medan arbete i storstad och vissa verksamheter kan innebära mer komplexa arbetsmiljöer.

Samtidigt ska resultaten tolkas som samband, inte orsakssamband. Att VVS har högre skadefrekvens betyder inte att verksamheten i sig orsakar skador. Skillnaden kan också spegla kundmix, projekttyp, rapporteringsbenägenhet eller säkerhetsrutiner som inte finns i datan.

Under arbetet insåg vi att modellens passform förbättrades för varje variabel som lades till, även out-of-sample. Att M3 presterar bättre än M2 på valideringsdatan utesluter inte att förbättringen saknar praktiskt värde. Skillnaden är liten (0,8 % lägre deviance) och Självrisk introducerar tolkningsproblem. Variabeln korrelerar med Omsättning, styrs delvis av kundens val av riskexponering, och gör att rate ratios inte längre isolerar en enskild riskfaktor. I en prissättningsmodell där varje koefficient ska motivera en premiejustering värderas tolkbarhet högre än marginell statistisk förbättring. Försäkringsbelopp exkluderades av samma skäl.

5.2 Modellval

XGBoost ger något lägre Poisson deviance än GLM, men förbättringen är mycket liten: cirka 0,21 % på valideringsåret 2024 och 0,08 % på teståret 2025. RMSE och MAE är i princip identiska, och GLM har något lägre portföljfel på 2025. Detta är inte ett tillräckligt stort mervärde för att byta huvudmodell. GLM M2 bör därför väljas som huvudmodell eftersom den är transparent och direkt användbar i prissättning. Rate ratios kan översättas till premiejusteringar, exempelvis högre premie för VVS, storstad och högre omsättning.

XGBoost fyller ändå en viktig roll som jämförelse-modell. Att den flexibla modellen främst använder samma tre variabler som GLM stärker slutsatsen att portföljens viktigaste riskstruktur redan fångas av GLM. Den bästa XGBoost-modellen använder dessutom grunda träd, vilket tyder på att sambanden i datan till stor del är additiva snarare än starkt komplexa.

5.3 Antaganden och begränsningar

Poisson-GLM bygger på antagandet att variansen ungefär motsvarar väntevärdet. Överdispersionskontrollen gav en kvot nära 1 (0,986), vilket stödjer att Poisson är ett rimligt val. Den höga andelen nollskador är därför inte i sig ett problem, utan en naturlig följd av låg skadefrekvens per försäkringsrad.

En central begränsning är att datan är artificiell och inte kommer från verkliga kunder. Detta problem illustrerades först när vi testade att inkludera alla tillgängliga variabler för GLM. Vi såg att modellen med alla variabler gav bäst prediktionsresultat, både in- och out-of-sample. En möjlig orsak är att datan är onaturligt stabil. Det generiska problemet med att inkludera många variabler i en regressionsmodell är att den blir överfittad. Om testdatan är för lik träningsdatan kan dock en överanpassad ändå prestera bra out-of-sample. Detta kan också förklara varför skillnaden mellan Poisson-GLM och XGboost inte blev stor. Teoretiskt borde XGboost fånga icke-linjära samband som GLM missar, men om sådana samband saknas från datan begränsas ML-modellen. För en rättvisare utvärdering borde modellerna tränas och testas på verkliga data.

Den viktigaste begränsningen är att modellen bara beskriver skadefrekvens. Den säger inget om skadornas storlek och kan därför inte ensam ge en fullständig premie. För faktisk prissättning behöver frekvensmodellen kombineras med en separat modell för skadekostnad.

En annan begränsning är att modellen antar att sambanden från 2021–2024 gäller även 2025. Testresultatet stödjer detta på portföljnivå, men antagandet kan brytas vid förändringar i inflation, villkor, skadehantering, lagstiftning eller portföljmix. Makroekonomiska förändringar kan fångas av omsättningen, men för att behålla noggrannheten om modellen ska användas bortom 2025 bör modellen följas upp årligen.

5.4 Praktisk användning och osäkerhet

På portföljnivå är modellen välkalibrerad. GLM predikterar 5 581 skador för 2025 jämfört med 5 520 observerade, vilket motsvarar ett portföljfel på +1,1 %. Konfidensintervallet för totalen innehåller det observerade utfallet, vilket stärker modellens praktiska användbarhet. För att illustrera hur modellen kan användas i prissättning beräknas den förväntade skadefrekvensen för en exempelprofil. Ett VVS-företag i storstad med 10 MSEK i omsättning och ett helårskontrakt ger:

$$\begin{aligned}\lambda &= \exp(\beta_0 + \beta_{verksamhet} + \beta_{geografi} + \beta_{omsättning} \cdot \ln(Omsättning)) \cdot Duration \\ &= \exp(-11,115 + 0,359 + 0,379 + 0,442 \cdot \ln(10\,000\,000)) \\ &= \exp(-3,25) \approx 0,039\end{aligned}$$

Den predikterade frekvensen är ungefär 1,8 gånger portföljens genomsnitt (0,021). I ett bestånd av 100 sådana kontrakt förväntas cirka fyra skador per år. Rate ratios från Tabell 2 kan på motsvarande sätt användas som multiplikatorer vid premiedifferentiering: VVS-faktorn 1,43 och storstadsfaktorn 1,46 multipliceras med bastariffens nivå för att ge den segmentspecifika premien.

På rad- och segmentnivå är osäkerheten större. Ovanliga kombinationer av verksamhet, geografi och omsättning bör därför hanteras försiktigare än vanliga kundprofiler.

Segmenttabellerna för 2025 visar att stora segment, exempelvis byggföretag och storstad, är relativt välkalibrerade, medan vissa mindre segment har större relativa avvikelser. Detta talar för att modellen kan användas som tariffstöd, men att små segment inte bör justeras mekaniskt utan aktuariebedömning.

Sammanfattningsvis, ger GLM M2 den bästa balansen mellan träffsäkerhet, stabilitet och tolkningsbarhet. XGBoost bör användas som kontrollmodell över tid, men inte som primär prissättningsmodell i nuläget.

6. Slutsats

Projektets huvudfråga var om skadeantal i entreprenadförsäkring kan förutsägas med kund-, verksamhets- och försäkringsdata, och om XGBoost ger ett tillräckligt mervärde jämfört med en tolkbar Poisson-GLM. Slutsatsen är att skadefrekvensen kan predikteras väl på portföljnivå. De viktigaste ratingfaktorerna är omsättning, geografiskt område och verksamhet. Högre omsättning hänger samman med högre skadefrekvens, Storstad har högre skadefrekvens än Landsbyggd och VVS har högre skadefrekvens än Byggföretag. Skillnaderna är tillräckligt tydliga för att motivera premiedifferentiering, men ska tolkas som samband snarare än orsakssamband.

XGBoost gav marginellt lägre Poisson deviance än GLM, men förbättringen var för liten för att motivera ett modellbyte. GLM M2 rekommenderas därför som huvudmodell. Den är stabil, transparent och ger rate ratios som kan översättas direkt till prissättning och segmenteringsbeslut. XGBoost bör i stället användas som challenger för att följa om mer komplexa samband får större betydelse i framtida data.

Analysen har några viktiga begränsningar. Modellen skattar endast skadefrekvens, inte skadekostnad, och räcker därför inte ensam för en fullständig försäkringspremie. Den bygger också på antagandet att sambanden från 2021–2024 är relevanta för 2025 och framåt. Variabelval och jämförelse mellan modellerna påverkas av syntetiska datan. För fortsatt arbete bör modellen kompletteras med en kostnadsmodell, följas upp årligen och utvecklas med mer detaljerade variabler som företagsålder, kundspecifik skadehistorik och mer detaljerad geografi.

7. Referenslista

- Chen, T. & Guestrin, C. (2016). XGBoost: A Scalable Tree Boosting System. Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785–794.
- Broström, A. & Wennberg, K. (2023). Data och modeller – en handbok för analys. Upplaga 1.1. Gleerups.

8. Appendix

8.1 *Github*

<https://github.com/Berget1411/risk-analysis>