



Sammanfattning: Data, Modeller och Verklighet, Kvantitativ affärs- och verksamhetsanalys

Kvantitativ affärs- och verksamhetsanalys (Kungliga Tekniska Högskolan)



Scan to open on Studocu

Data, modeller och verkligheter av Anders Broström

Kapitel 1 – Analytisk Förståelse

1.1 Kunskap för dataåldern

- Stora delar av vardagen formas av kvantitativ analys, ex. digitala mötesplatser, opinionsmätningar, undersökningar etcetera
- Systematisk analys av data kan ge överblick och insikt vilket hjälper vid beslutsfattande
- Vissa beslut kan även automatiseras med AI och robotar
 - Viktigt med analytisk förmåga för att hantera detta samt att vara kritisk i analyser gjorda av andra samt att göra kloka val i egen analys

1.2 Tilltro till data

- Kvantitativa data beskrivs som bästa och enda källan till välgrundad kunskap
- Bättre än kvalitativa data (undviker bekräftelsebias och godtycklighet)

1.3 Analytiska syften

- Skillnad mellan:
 - Deskriptiv analys
 - Syftar till att beskriva ett dataset, ett fenomen
 - Prediktiv analys
 - Syftar till att förutsäga framtiden
 - Preskriptiv analys
 - Syftar till att algoritmiskt välja ut det bästa beslutsalternativet
- Otydlighet kring dessa begrepp beror på att analytiker har olika expertis (skillnad mellan de som har datateknisk bakgrund och bakgrund inom ekonomi och statistik)
- Ungefär: Datavetare ser det som uppgift att visualisera data och mönster kring relativt väldefinierade frågeställningar
- Den mer samhällsvetenskapligt skolade analytikern ser som sin uppgift att möjliggöra nya insikter kring breda frågeställningar

Kapitel 2 – Att beskriva data

Analytikers uppgift: Vilka relevanta mönster döljer sig i data?

- Hur gör vi för att avgöra vilka mönster som är relevanta?
- Hur kopplar vi mönster i data till verkligheter som undersöks?
- Vilka verktyg kan vi använda för att beskriva en datamängd?

2.1 Beskrivningar av en mätserie

- Fundamental beskrivning som görs för att sammanfatta information ryms i en serie med data med ett eller flera mått.
- Vanliga mått:
 - Medelvärde
 - Median
 - Typvärde (mode)
 - Spridningsmått ex. varians eller standardavvikelse
- Dessa mått skapar överblick och kan jämföras med andra. Kan sammanfattas i ett låddiagram som grafiskt representerar kvartiler, min. och max. för ett flertal dataserier
- Studera fördelning m.h.a figur:
 - Horisontell axel – värden på mätserien
 - Vertikal axel – hur vanligt förekommande är värdet
- Alternativt täthetskurva – (som ett histogram där $dx \rightarrow 0$)
- Visualisering:
 - Överskådligt
 - En utgångspunkt för att jämföra data med teoretiska fördelningar $\rightarrow$ hjälper oss göra rimliga antaganden
 - Diagrammet kan även ge information om eventuella extremvärden (outliers) $\rightarrow$ måste dessa justeras eller inte?

2.2 Jämförelser mellan mätserier

- Intressant för en analytiker och kan göras numeriskt eller grafiskt
- Kvalificerad jämförelse: hypotes-test
- Enklare jämförelser: ex. huruvida det finns en statistiskt signifikant skillnad mellan två medelvärden
 - Utgår från noll-hypotesen att medelvärdena inte går att skilja från varandra och provas ofta i form av ett t-test (utgår från normal-fördelade data)
 - Fungerar för det mesta pga. CGS, men inte vid för små datamängder eller alltför spridda datapunkter
- Situationer där vi har flera mätserier att undersöka: ANOVA (analysis of variance)
 - Kan ex. användas för att prova noll-hypotesen att samtliga mätserier har samma medelvärde $\rightarrow$ om det inte ger stöd till att förkasta kan vi tolka det som ovan
 - Vad gör vi om testet faller ut med ett p-värde under vår valda signifikansgräns? Gå vidare med mätserier som skiljer ut sig från andra i signifikant grad
 - Två och två med t-test? När ett flertals hypoteser testas ökar sannolikheten att förkastas genom ren slump. I statistikprogram finns moduler för post-hoc test att köra efter ANOVA som korregerar detta. Det går även att göra Bonferroni-korrigerad och höja svårighetsgraden för hur stora skillnader som krävs för att förkasta noll-hypotesen

2.23 Beskrivningar av samvariation

- Ligger ofta i vårt intresse att studera hur två data-serier håller sig till varandra.
- Både numeriska och grafiska metoder fungerar
- Vi kan då använda kovarians eller dess standardiserade form korrelationskoefficienten
 - Stark korrelation: värde nära -1 eller 1 (negativ korrelation resp. positiv korrelation)
- För mått som temp. Ger korrelationskoefficienter en fullständig beskrivning av samvariation
- Finns även möjlighet att dataserier kovarierar vid små men ej stora värden eller vice versa → Vi behöver utnyttja grafisk representation av våra data i form av ett spridningsdiagram (scatter plot)

2.4 Sammanfattande råd

- Alltid bra att skaffa en överblick över nya data
- God beskrivning förenklar så långt som möjligt och förvanskar så lite som möjligt
- Arbetet börjar nästan alltid med frågan vilka dataserier dina data innehåller
- Undersök också samvariation mellan samtliga variabler i form av en numerisk korrelationstabell (med korrelationskoefficienter för alla kombinationer av variabler) eller en grafisk korrelationsmatris (med spridningsdiagram för alla korrelationer av variabler)

Kapitel 3 – Att dra slutsatser från data – validitet och reliabilitet

- Vad kan vi använda datan till?
- Konkreta arbetet handlar om att synliggöra och bearbeta data
- Oavsett metod kan det inte hjälpa dig om datan inte är väl matchad/representerar verkligheten du är intresserad → Krävs alltså hög reliabilitet och validitet av data för god analys

3.1 Två informella definitioner

- Reliabilitet ≈ Data är konsistent
- Kan ses som vårt sätt att mäta gör att våra datapunkter ligger nära det sanna värdet
- Reliabilitet kan också förstås som att upprepade mätningar av samma underliggande storhet ger samma eller liknande utfall
- Studier om spridningen av våra mätningar gör det möjligt att avgöra reliabiliteten
- Ofta svårare att avgöra om vårt sätt att mäta är rättvisande - Validitet (ex. en felkalibrerad våg kan ge samma resultat 10 gånger, men ändå visa 10% mer än verkliga värdet)
- Krävs ofta flera olika slags data eller flera kompletterande datapunkter för att kunna representera den teoretiska storheten med hög validitet
- Många modeller har låg extern validitet: samband mellan två variabler fångas som gäller en situation, men andra möjliga situationer som kan ge samma samband fångas inte.

Reliabilitet och validitet är kompletterande begrepp som beskriver förutsättningar för att ett visst sätt att mäta ska ge användbara data i en analys

3.2 Hur vet jag om jag har problem med reliabilitet och validitet?


- Vag skattning behöver inte innebära låg validitet
- Anknytning till de stora talens lag: intuitivt är ett medelvärde mer pålitligt ju fler mätvärden vi har (gäller då observationerna är oberoende och den variabel vi studerar är slumpmässigt dragen)
- För att bedöma problem med reliabilitet och validitet måste du bedöma hur dina data förhåller sig till den verklighet du vill veta något om – det vill säga förstå den datagenererande processen (DGP)
 - Handlar om 2 sorters förståelse: Insikt i verkligheten vi är intresserade av samt insikt i de metoder som använts för att samla data från verkligheten
 - Ex. trafik kring skola – lägg till variabel för veckodag – mer insikt om dgp (ex. mer trafik på fredagar) → utvecklar en villkorad stokastisk variabel → nå god reliabilitet genom att besluta om rätt mått (ex. antal bilar per timme, veckodag)
 - Förståelse för DGP låter oss minimera brus

3.3 Några vanliga misstag (s.11)

- Enkla, ogenomtänkta frågor om komplexa företeelser ex. öppet ställda frågor, eller svårtolkade frågor i undersökningar
 - Ex. vid frågor om värderingar
- Om frågan leder mot ett visst svar (då påverkar vi datainsamlingen) → Låg validitet
- Enkätundersökningar
- Övertolkning av data: ex. patent vs. Innovationsdata
- Sänk anspråken om data inte rakt av motsvarar den underliggande storhet vi vill undersöka
 - Ex. studien om innovation blir en studie om patent i stället
 - → Kan över tid ske en glidning, där måttet övertar platsen som den storhet vi intresserar oss för (tydligt gällande många KPIer)

3.4 Validitet och urval

- Construct validity: Att representera en teoretisk storhet med en mätbar storhet på ett riktigt sätt – fokus på mått och mätverktyg
- I vissa sammanhang är det istället urvalet av data som är en främsta utmaningen för att uppnå god validitet – hjälper inte att ha perfekt data om den inte representerar den grupp eller mängd som ska fångas
- Antag att gruppen som vi vill undersöka kallas *målpopulation*.
- *Rampopulation* är den grupp som vi kan nå för undersökning
- Slutligen utgörs vårt urval eller stickprov av data från den grupp från vilken vi lyckas få användbara data



- Validiteten i datan kommer bero på hur väl stickprovet/urvalet representerar målpopulationen
- Ideal: totalundersökning (samtliga i målpopulationen undersöks)
- Nästbäst: Om urvalet inte på viktigt sätt avviker från målpopulationen. Uppnås typiskt genom slumpmässig dragning från en rampopulation som är identisk med målpopulationen
- Om målpopulationen består av undergrupper med skillnader → Selektionseffekter

3.5 Felaktiga data och rensning

- Vissa fel: Mätfel, manipulationer och överföring av data → felaktigheter
- Händelser som uppstått vid urval → enstaka observationer
- Oavsett hur fel uppstår → lägre validitet och reliabilitet
- Ofta svårt att upptäcka fel. Utgångspunkt: titta på *outliers* (värden som sticker ut) och avgöra om dessa går att lita på och därefter justera (behålla/radera)
- Vanligaste form av justering: *winsorizing* – höga/låga värden ersätts med ett annat värde (ex. ta 90% av värdena som ligger närmast medelvärdet och ersätta med 5e percentilens värde respektive 95e percentilens)
- Gör dock enbart justeringar med utgångspunkt för vår förståelse för hur datan kom till eller för hur felen kom till då de kan påverka analysen
- "Ett påstående är bara vetenskapligt om det är falsifierbart, och om det inte är falsifierbart säger det inget om verkligheten" – Karl Popper, 1934

Kapitel 4 – Att studera orsak och samband

Analytikers arbete syftar ofta till att utforska möjliga framtider – och där är "The Scientific Method" en guldstandard

4.1 Ett recept för kunskap

- The Scientific method: innebär att analysen formas kring en eller flera hypoteser som sätts upp på basen av den bästa tillgängliga kunskapen vi vill studera
- Tumregel: En hypotes ska vara falsifierbar – analytikern ska på förhand kunna uttala sig om vilka (ännu oobserverade) empiriska utfall som leder till att hypotesen förkastas
 - Detta arbetssätt utgör normen för vetenskapligt arbete inom naturvetenskapliga, medicinska och tekniska områden
 - Mer splittrat inom samhällsvetenskap
 - Beror på i vilken mån dessa frågor handlar om att fastställa orsak och samband, och vilka typer av frågor denna data ska svara på
 - Beror även på om det är en prediktiv analys
-

4.2 Ny teknik och gamla principer

- Principen om den hypotetisk-deduktiva anstatsen är gammal
- Ny teknik → fler uppgifter kan överlämnas till algoritmer och AI
- Även om mönster hittas av algoritmer vinner vi inte ny kunskap förrän dessa mönster kan omsättas i förklaringar till varför mönstrena uppstår

4.3 Förutsättningar för kontrafaktisk analys

- Vilken sorts data behöver vi tillgång till för att testa hypoteser?
- Grundprincipen: rätt slutsatser om kausalitet kräver kontrafaktisk analys; dvs att vår data gör det möjligt att så långt som möjligt analysera hur ett visst utfall hade blivit med annan historik
- Första förutsättning: Data med variation.
 - Särskilt stor variation om det finns stor osäkerhet i mätning eller annan form av felkällor och brus kring det samband vi vill studera
 - Vi vill alltså sträva efter så mycket användbar variation som möjligt i förhållande till störningar och mätfel
 - Ideala förhållandet kallas för hög *signal-to-noise-ratio*
 - Standardfelet för en regressionskoefficient för variabeln X bestäms av

$$s_{\beta} = \frac{s_{\epsilon}}{\sqrt{n-1}s_x}$$

där s_{ϵ} är standardfelet i regressionens felterm och s_x är standardavvikelsen för X .

- Viktigt att vara noga med slutsatser med begränsad variation
 - Validitet gäller bara (som bäst) det intervallet som våra data är hämtade från
- Andra förutsättning: Tillgång till data som så långt som möjligt möjliggöra rekonstruktion av ett tänkt orsaks-samband. Två tum-regler för detta
 - (4.3.1) 1: Experimentell data är bättre än kvasi-experimentella data
 - (4.3.2) 2: Paneldata är bättre än tvärsektionell data

4.3.1 Experimentella data är bättre än kvasi-experimentella data

- Experimentella data samlas in genom experiment, i bästa fall en randomiserad kontrollstudie (kräver att vi har kontroll över den faktor som undersöks och full tillgång till försöksobjekt) – en test-grupp och en *kontrollgrupp* (ska representera kontrafaktiska utfallet)
- Oftast kan vi inte kontrollera alla nyckelfaktorer och hänvisas till observationsstudier
- Observationsstudier är näst bäst: insamling av data från en verklighet vi inte manipulerat och analyserar den som om den vore experimentell → kallas därför *Kvasi-experimentell*
 - Inte möjligt att isolera faktorer → samla in data på alla andra faktorer som påverkar vår beroende variabel och på statistisk väg försöka i efterhand isolera samband → Kan på olika sätt rensa bort den trenden för att få kvar kontrafaktiska efterfrågan som hade observerats om trenden inte existerat
- Mellanting mellan experimentell och kvasi-experimentell studie är en analys som kan utnyttja *ett naturligt experiment*
 - Kännetecknas av att systemet i vårt intresse varit utsatt för exogen påverkan (någon form av förändringar utifrån systemet som påverkat de variabler vi är intresserade av) → tar oss närmare en "allt-annat-lik" situation som kan åstadkommas i ett laboratorium

4.3.2 Paneldata är bättre än tvärsektionell data

- *Panel* = Data som är organiserad så att går att studera variation både över variationsenheter och över tid
- *Tvärsektionellt dataset* = mäter variabler för många observationsenheter men enbart vid ett tillfälle
- Paneldata kan utnyttjas på två sätt:
 - Variation mellan observationsenheter och variation över tid kan användas för att skatta samband, och större variation ger mer precisa skattningar
 - Kan även avstå från att analysera skillnader mellan observationsenheter, och istället enbart basera sina skattningar på skillnader över tid
 - Fördelen blir att det blir möjligt att isolera alla tidsinvarianta faktorer

Kapitel 5 – Modeller, data och verkligheter (s. 19-23)

- Modell = förenklad representation av komplex och mångtydig verklighet
- "Mentala tumregler" ≈ modeller som representerar erfarenhet och tolkas som ett mönster = Informella modeller

5.1 Vad är en bra modell?

- Begreppet "teori" centralt
- Syftar för analytiker på tillgänglig systematisk förståelse av ett fenomen → Ger oss ett angreppssätt, ett perspektiv och en överblick över fenomenet
- Modell: Konkret manifestation av en teori
- För att sätta upp en god modell (som hjälper oss förstå verkligheten) behövs:
 - Grunda den i teoretisk förståelse
 - Avgöra de viktigaste faktorerna är och hur de förhåller sig till varandra

- En bra modell behöver inte beskriva verkligheten exakt, eller vara för detaljerad utan den ska så effektivt som möjligt hjälpa oss få syn på intressanta aspekter av verkligheten
- Riktlinje: Försök modellera det avgränsade problem som du ska försöka beskriva och förstå snarare än verkligheten
- Valet av analysmetod beroende på vilken data vi har: beror på hur man ser på förhållandet mellan det som ska förutsägas och den historik som används för att leta mönster
- 3 typfall:
 - 1. Modellera ett system som fungerar ungefär på det sätt det gjorde under den period då data genererades kan man förlita sig på **algoritmiska metoder** (för det mesta maskininlärningsalgoritm)
 - Exempel: Modellera ett rent tekniskt system, prognos med statistisk metod
 - 2. Modellera ett system som är föränderligt: modellera utifrån teoretisk kunskap. Parametrar från tidigare studier och etablerad kunskap, och data
 - Exempel: Adaptiva prognosmodeller
 - 3. Modellera och ta fram underliggande principer i data-genererade systemet. Parametrar från tidigare studier och etablerad kunskap, och data, men här är parametrarna i sig intressanta (snarare än modellen)
 - Exempel: Undersökningar av aspekter av mänskligt beteende eller klinisk prövning av ett nytt läkemedel
- I en föränderlig värld behöver vi alltså arbeta teori-drivet för att uppnå god reliabilitet och validitet

5.2 Modeller och samband

- Stokastisk variabel: En grundläggande form av modell
 - Enkel form: utfall beror av fasta parametrar som definierar fördelningen
- Fokus kan även ligga på att fånga samband mellan variabler
- Kausalt samband i fokus i matematiskt definierade modeller

5.3 Två sorts orsakssamband

- Deterministiska kausala samband: ex. Newtons Klassiska Ekvationer
- Alla samband är inte lika regelbundna
 - Exempel: medicin/ekonomi är det bara rimligt att tänka sig statistiskt kausalt samband
 - Ex. på statistiskt kausalt samband: 100 barn till föräldrar med höga inkomster vs. 100 barn med låga inkomster → Deterministiska sambandet "barn till höginkomsttagare får alltid högre lön än barn till låginkomsttagare" är inte rimligt
- Går oftast inte att dra kausala slutsatser från data, framförallt inte från tvärsnittell data
- Går ej att hävda att: en variabel som är mer statistiskt signifikant korrelerad med Y har ett starkare kausalt samband med Y. Däremot gäller det åt andra hållet (Kausalt samband innebär förmodligen korrelation)

5.4 Olika sorters variabler

- Variabel: ett centralt begrepp i matematik/statistik
- Viktigt att förstå vilket utfallsrum som variabeln kan ha
- Skillnad mellan variabler som antar kvantitativa vs. Kvalitativa värden
 - Kvalitativa utfallsrum med nominell skala: ex. färger, genus – kan kategoriseras men saknar skala eller rangordning
 - Vissa har dock en skala: Ex. betyg från A-F (ekvidistanta utfall blir: 5, 4.5, 4 etc.
 - Kvantitativa utfallsrum kan kodas som siffror: ex. färger som antar värdet 1 eller 0
 - Kvantitativa utfallsrum kan vara både kontinuerliga och diskreta (antar enbart heltalsvärden)
- Kan även vara relevant att tala om observerade och latent variabler
 - Observerade värden: koppling mellan data och modell är relativt direkt
 - Latent variabel: en abstraktion – fångar upp en viktig konceptuell faktor som är omöjlig att fånga upp i observerade data
 - Ex. mänskliga beteenden

5.5 Att modellera relationer mellan variabler

- Hur ser sambandet mellan variablerna ut?
- 3 Grundläggande Relationer:
 - 1. Direkta samband: utfallet av Y beror av utfallet av X.
 - 2. Indirekta medierade samband: utfallet av Y beror av utfallet av Z, som i sin tur beror av utfallet av X.
 - 3. Indirekta modererade samband: utfallet av Y beror av utfallet av Z, och styrkan av det sambandet beror av utfallet av X
- Enklaste formen i modellering: anta linjärt samband
- Andra alternativ: log-linjärt (om ex. Y är avtagande), Kvadratisk samband: Y beror av X och X^2

5.6 Modellen som analytiskt arbetsredskap

- Analys som följer grundläggande vetenskaplig (hypotesprövande) metod kan ha flera modeller
 - Kan ex. representera etablerad och välbelagd kunskap
 - Flera modeller kan användas för att representera en hypotes → modeller som representerar hypoteser som funnit bäst stöd i analysen = resultat och utfall av vårt arbete

Kapitel 6 – Att skapa reda i komplexitet

- Exempel på analys av frukt som äts av slumpmässig grupp under två månader

6.1 Enkla medelvärden

- Beräkna medelvärden av fruktkonsumtion för män respektive kvinnor (relativt god validitet då det svarar på ursprungliga frågan)
 - Däremot saknas vi andra faktorer som påverkar ex. total konsumtion, inkomst, kroppsvikt etc.

6.2 Normering av data

- Ex. studera kvoten fruktkonsumtion i förhållande till total matkonsumtion och hur detta skiljer sig mellan könen

6.3 Trimma data

- Trimma stickprovet för att minska inflytandet av faktorer som kan vara korrelerade med den variabel som vi är mest intresserade av och samtidigt skilja på könen
 - Ex. om vi tror att kvinnor som tränar minst en gång per vecka äter mer frukt
 - Då kan vi ex. ta bort de som inte tränar alls → Innebär dock att vi enbart har validitet för de som tränar och att vi får sämre precision i våra punktskattningar

6.4 Regressionsanalys

- Tillämpning av regressionsanalys: modellering av fruktkonsumtion som funktion av kön, träningsfrekvens etc.
- Tolkar därefter koefficientestimatet på variabel kön som mått på styrkan av ett eventuellt samband mellan kön och preferens för att äta frukt
- Uppmärksamma på: Estimat från enkel linjär regressionsmodell bara är väntevärdesriktiga då den oberoende variabel är exogen i sammanhanget (om ytterligare faktorer samvarierar den beroende och oberoende variabel lider skattningen av skevhet)
 - Detta kallas för att modellen lider av endogenitetsproblem till följd av "omitted variable bias"
 - Samma typ av problem om beroende variabeln påverkar den oberoende – detta kallas simultanitet
- Endogenitet är ett hinder för att etablera orsakssamband
- Experimentell ansats vid endogenitetsproblem
- Ofta används multivariat regressionsanalys vid denna typ av analys (låter oss modellera en beroende variabel som funktion av flera faktorer då dessa är mätbara, exogena och vi kan samla tillräckligt med data)
- Mer avancerad multivariat regressionsanalys används om endogenitetsproblem föreligger i kvasi-experimentell data från observationsstudier

Kapitel 7 – Prediktion

- I många sammanhang är analysarbetet inriktat på prediktioner snarare än orsak-verkansamband
- Ex. inom finansiell analys, opinionsundersökningar och meteorologi

7.1 Validering

- God prediktion kräver en modell som ligger nära den datagenererande processen (samt att processen inte ändras alltför mycket över tid), men det krävs inga djupare insikter om hur modellen fungerar
 - Modellen kan liknas vid en svart låda
- Finns tydligt kriterium för hur väl en viss modell löser uppgiften
 - Bra modell gör precisa prediktioner på ett dataset som den inte tränats på
 - Detta kallas ofta för "prediktiv förmåga för observationer utanför stickprovet"
- Typiskt arbetssätt: 70% används för skattning och mindre del för utvärdering
 - Validering enligt samma princip används ofta för att jämföra olika modeller – då används ofta korsvalidering (tillgängliga datamängden delas in i ett flertal delar som sätts ihop till ett flertal olika träningsätt och testset)

7.2 Handlar inte alla analyser om att förutsäga framtiden?

- Vad skiljer egentligen det beskrivande och det normativt preskriptiva från prediktiv analys?
 - Fråga om filosofi och prioriteringar
- Underliggande drivkraft: med viss precision uttala oss om framtida händelser
- Modell som inrymmer väl belagda kausala samband bör också vara bra bas för prediktion
- Enbart prediktiv analys har dock ofta egna metoder (prognosen står i fokus)
 - Grundläggande skillnad: Genom starkare antaganden om stabilitet i DGP kan farhågor om validitet läggas åt sidan och reliabilitet kan maximeras
 - Kan dock innebära mycket enkla modeller, men algoritmiskt sökande efter en modell med maximal prediktionsförmåga leder ofta till modeller med komplex struktur

7.3 Prognosmodeller

- Modeller som syftar till att göra prognoser kan beskrivas som ett mellanting mellan rent prediktiva och kausala modeller
- Vi utgår i regel från en funktionell form som ges av vår teoretiska förståelse (som i kausala modeller)
 - Innebär här att modellera framtida utfall som funktion av givna mönster (tidstrend, säsongstrender) i historiska utfall
 - Fördel (i jmf. med black box ansats) är att prognosmakaren kan göra förändringar utifrån förståelse av DGP
 - Ex. modellering av efterfrågan av vara efter pandemin: vi kan justera så att förväntan inte baserat alltför mycket på föregående år